

گزارش نهایی پروژه: تحلیل کیفیت و پیش‌پردازش داده‌های نقل‌وانتقالات فوتبال

تهیه شده توسط: ساسان نیک جو تاریخ: آذر ۱۴۰۲

مقدمه و تعریف مسئله

هدف اصلی این پروژه، تبدیل یک مجموعه داده (Dataset) خام و غیرقابل اعتماد شامل ۴۷۰۰ رکورد از اطلاعات بازیکنان فوتبال، به یک مجموعه داده تمیز، استاندارد و آماده برای تحلیل بود. چالش اصلی، وجود حجم بالایی از داده‌های گمشده، نویزهای متنی و مقادیر پرت (Outliers) بود که می‌توانست نتایج هرگونه مدل‌سازی را با خطا مواجه کند.

فاز اول: اکتشاف و تحلیل اولیه داده‌ها (Data Exploration)

در این مرحله، ساختار کلی داده‌ها مورد بررسی قرار گرفت تا درک اولیه‌ای از توزیع متغیرها حاصل شود.

۱-۲. مشاهدات آماری

- ابعاد داده: دیتاست شامل ۴۷۰۰ سطر و ۱۰ ستون بود.
- ناهنجاری‌های مشاهده شده:
 - در ستون Age مقادیر غیرمنطقی مانند ۲۸۸ سال و ۰ سال مشاهده شد.
 - در ستون Transfer_fee انحراف معیار بسیار بالا بود که نشان‌دهنده اختلاف شدید طبقاتی بین بازیکنان آماتور و ستارگان فوتبال است.

۲-۲. تحلیل‌های بصری

- نمودارهای هیستوگرام نشان دادند که توزیع قیمت‌ها نرمال نیست و چولگی (Skewness) شدید دارد.
- نمودار پراکندگی (Scatter Plot) رابطه بین «ارزش بازار» و «قیمت نهایی» را به صورت یک قیف نشان داد؛ به این معنی که با افزایش قیمت بازیکن، واریانس و پراکندگی قیمت نیز افزایش می‌یابد.

فاز دوم: ارزیابی کیفیت داده (Data Quality Assessment)

داده‌ها بر اساس ۵ معیار استاندارد کیفیت داده (Data Quality Metrics) ممیزی شدند. نتایج این ممیزی مشکلات بحرانی زیر را آشکار کرد:

شرح مشکل	وضعیت	معیار کیفیت
۱۳۲۱ رکورد (معادل ۲۸٪) در ستون حیاتی Market_value مقدار نداشتند.	بحرانی	کامل بودن (Completeness)
۳۳۶ رکورد در ستون Season فرمت استاندارد (YYYY-YYYY) نداشتند. همچنین کاراکترهای خراب در نام تیم‌ها وجود داشت.	هشدار	اعتبار (Validity)
وجود سن‌های اعماری (مانند ۲۴.۵) و سن‌های غیرممکن (مانند ۲۸۸) که با واقعیت فوتبال تضاد داشتند.	هشدار	دقت (Accuracy)
ستون Position دارای ۳۸۶ غلط املایی و تایپی بود (مثلاً heft Winger به جای Left Winger).	هشدار	قالب‌بندی (Formatting)
خوشبختانه رکورد تکراری (Duplicate) در داده‌ها یافت نشد.	مطلوب	سازگاری (Consistency)

فاز سوم: پیش‌پردازش و پاکسازی (Preprocessing & Cleaning)

برای رفع چالش‌های شناسایی شده، اقدامات اصلاحی زیر انجام شد:

۱-۴. استراتژی‌های پاکسازی

1. مدیریت داده‌های پرت (Outliers): با اعمال فیلتر منطقی، تنها بازیکنان با سن بین ۱۵ تا ۴۵ سال نگه داشته شدند. سن‌های پرت و اعشاری اصلاح یا حذف شدند.
2. جایگذاری داده‌های گم‌شده (Imputation): برای پر کردن ۲۸٪ داده گم‌شده در ستون Market_value، از روش میانه (Median) بر اساس پست بازی استفاده شد. (استفاده از میانه به جای میانگین باعث شد که قیمت‌های نجومی ستارگان فوتبال، تخمین قیمت بازیکنان معمولی را خراب نکند).
3. استانداردسازی متون: با استفاده از نگاشت متن (Text Mapping)، تمامی ۳۸۶ غلط املائی در ستون پست بازی اصلاح شدند و نام‌های حاوی کاراکترهای غیرمجاز حذف گردیدند.

۲-۴. کاهش ابعاد و مهندسی ویژگی

برای بررسی ساختار داده‌ها، سه روش کاهش ابعاد مقایسه شدند:

- PCA روش خطی: نتوانست تفکیک مناسبی ایجاد کند (به دلیل ماهیت غیرخطی داده‌های فوتبال).
- Kernel PCA: عملکرد متوسطی داشت.
- t-SNE: روش غیرخطی: بهترین عملکرد را داشت و توانست بازیکنان را بر اساس شباهت ویژگی‌هایشان (مثل دروازه‌بان‌ها، مدافعان و مهاجمان) به خوبی خوشه‌بندی کند.

فاز چهارم: تحلیل نهایی و دستاوردها

پس از پاکسازی کامل، تحلیل نهایی روی ۳۶۳۰ رکورد تمیز انجام شد.

۱-۵. پاسخ به سوالات کلیدی پروژه

1. مهم‌ترین عامل تعیین‌کننده قیمت بازیکن چیست؟

○ ویژگی ارزش بازار (Market_value) با ضریب همبستگی ۰.۵۷+ بیشترین تاثیر را دارد.

2. آیا زمان (فصل بازی) تاثیری دارد؟

○ بله. ویژگی Season_Year دارای همبستگی ۰.۲۶+ است که نشان‌دهنده تورم در فوتبال است (بازیکنان در سال‌های اخیر گران‌تر شده‌اند).

3. رابطه سن و قیمت چگونه است؟

○ همبستگی خطی سن نزدیک به صفر (۰.۰۱-) است، اما نمودارها نشان دادند که این رابطه غیرخطی (سهمی) است. قیمت بازیکنان تا ۲۶ سالگی صعودی و پس از آن نزولی است.

نتیجه	بعد از اصلاح	قبل از اصلاح	معیار
✓ تمامی نواقص برطرف شد.	۱۰۰٪	۷۱.۹٪	کامل بودن
✓ داده‌های پرت و غیرمنطقی حذف شدند.	۱۰۰٪	۹۸.۰٪	دقت
✓ تمامی فرمت‌های متنی و زمانی استاندارد شدند.	۱۰۰٪	۹۲.۸٪	اعتبار