

گزارش جامع پروژه داده‌کاوی: تحلیل transactions

مقایسه الگوریتم‌ها و تحلیل کیفی الگوهای استخراج شده

۱. توصیف مجموعه داده (Dataset Description)

در این پروژه، مجموعه داده‌ای شامل ۹۹۹ تراکنش و ۱۶ ویژگی (قلم کالا) مورد بررسی قرار گرفت. این داده‌ها نشان‌دهنده transactions مشتریان یک فروشگاه خرده‌فروشی هستند. اقلام موجود شامل کالاهای اساسی مانند شیر، شکلات، کره، بستنی، ماست، نان و... می‌باشند.

مشخصات فنی و آماده‌سازی داده‌ها:

- ساختار اولیه: داده‌ها به صورت یک دیتافریم با مقادیر True/False بودند که نشان‌دهنده حضور یا عدم حضور هر کالا در هر تراکنش است.
- پاکسازی: ستون مزاحم Unnamed: 0 که حاوی ایندکس عددی بود حذف گردید تا در فرآیند کاوش نویز ایجاد نکند.
- تبدیل فرمت: برای استفاده در الگوریتم‌های مختلف، داده‌ها به دو فرمت Set (برای الگوریتم دستی) و ماتریس Boolean (برای کتابخانه) تبدیل شدند.

۲. الگوریتم‌های انتخابی و نحوه پیاده‌سازی

برای استخراج الگوهای پرتکرار و قوانین انجمنی، از دو رویکرد متفاوت جهت مقایسه فنی و آموزشی استفاده شد:

الف) الگوریتم Apriori (پیاده‌سازی دستی - From Scratch)

این الگوریتم بدون استفاده از هیچ تابع آماده‌ای و صرفاً با منطق برنامه‌نویسی پایتون پیاده‌سازی شد. مراحل کلیدی پیاده‌سازی عبارتند از:

- تولید کاندیدا (Join Step): کاندیداهای طول k با ترکیب الگوهای پرتکرار طول k-1 ساخته شدند.
- هرس کردن (Pruning Step): بر اساس اصل Apriori، اگر یک کاندیدا دارای زیرمجموعه‌ای باشد که پرتکرار نیست، آن کاندیدا بلافاصله حذف می‌شود تا محاسبات کاهش یابد.
- محاسبه Support: با پیمایش لیست تراکنش‌ها، تعداد تکرار هر کاندیدا شمرده شد.

ب) الگوریتم FP-Growth (کتابخانه mlxtend)

جهت اعتبارسنجی نتایج و مقایسه سرعت، از پیاده‌سازی استاندارد کتابخانه mlxtend استفاده شد. این الگوریتم برخلاف Apriori کاندیدا تولید نمی‌کند، بلکه با ساخت یک درخت فشرده (FP-Tree)، پایگاه داده را فشرده کرده و الگوها را استخراج می‌کند.

ج) استخراج قوانین انجمنی (فاز ۲)

پس از یافتن الگوها، قوانین انجمنی (Association Rules) به صورت کاملاً دستی محاسبه شدند. توابع جداگانه‌ای برای محاسبه معیارهای Confidence، Lift، Chi-Square و Kulczynski نوشته شد.

۳. تحلیل حساسیت پارامتر Min-Support

پارامتر min_support تعیین‌کننده حد آستانه برای پرتکرار بودن یک الگو است. در این پروژه مقدار 0.2 (۲۰٪) انتخاب شد. تاثیر تغییر این پارامتر در هر دو الگوریتم به شرح زیر است:

اگر مقدار Min-Support کاهش یابد (مثلاً ۰.۰۵):

- انفجار ترکیبی: تعداد الگوهای کشف شده به شدت افزایش می‌یابد.
- افت عملکرد Apriori: به دلیل ماهیت تکرارشونده Apriori، زمان اجرا به صورت نمایی رشد می‌کند.
- ایجاد نویز: الگوهای تصادفی و کم‌اهمیت وارد نتایج می‌شوند.

اگر مقدار Min-Support افزایش یابد (مثلاً ۰.۴):

- حذف الگوهای ترکیبی: تنها اقلام تکی بسیار پرفروش (Best-sellers) باقی می‌مانند.
- از دست رفتن دانش: الگوی مهمی مثل {شیر، شکلات} که پشتیبانی ۲۱٪ دارد، با این تنظیمات حذف می‌شود.

نتیجه: مقدار ۰.۲ تعادل بهینه‌ای بین "تعداد الگوها" و "معناداری آماری" ایجاد کرد.

۴. مقایسه عملکرد الگوریتم‌ها

جدول زیر مقایسه دقیقی بین پیاده‌سازی دستی Apriori و کتابخانه FP-Growth ارائه می‌دهد:

معیار ارزیابی	Apriori (دستی)	FP-Growth (کتابخانه)	تحلیل نهایی
زمان اجرا (Run Time)	~ 0.0083 s	~ 0.0092 s	در داده‌های کوچک، سربرار (Overhead) ساخت درخت FP باعث شد سرعت آن مشابه Apriori باشد.
دقت (Accuracy)	۱۰۰٪	۱۰۰٪	تطابق کامل نتایج
کیفیت الگوها	۲۲ الگوی یکسان	۲۲ الگوی یکسان	هر دو روش دقیقاً به یک خروجی رسیدند.

۵. تحلیل کیفیت الگوهای استخراج شده

در فاز دوم، قوانین انجمنی با شرط $\text{Min-Confidence} = 0.5$ استخراج شدند. جدول زیر خروجی نهایی پیاده‌سازی دستی الگوریتم است که تمام معیارها را نشان می‌دهد:

قانون (Rule)	Support	Confidence	Lift	Chi-Square	Kulczynski
{Milk} → {chocolate}	0.211	0.521	1.236	27.69	0.511
{chocolate} → {Milk}	0.211	0.501	1.236	27.69	0.511
{Ice cream} → {Butter}	0.207	0.505	1.201	20.36	0.499

الف) تحلیل الگوهای قوی (Strong Patterns)

قوی‌ترین الگوی کشف شده، رابطه بین شیر (Milk) و شکلات (Chocolate) است:

Milk → Chocolate

- $\text{Lift} = 1.24 (> 1)$: خرید شیر باعث افزایش ۲۴ درصدی احتمال خرید شکلات شده است (همبستگی مثبت).
- $\text{Chi-Square} = 27.69 (> 3.84)$: نقطه قوت اصلی! این عدد بالا نشان می‌دهد که این رابطه کاملاً معنادار و غیرتصادفی است.
- $\text{Kulczynski} = 0.51$: تعادل خوبی در رابطه دوطرفه وجود دارد.

ب) تحلیل الگوهای ضعیف (Weak Patterns)

الگوهای ضعیف (که در مراحل هرس کردن حذف شدند) ویژگی‌های زیر را دارند:

- $\text{Lift} \approx 1$: دو کالا مستقل هستند و خرید یکی تاثیری بر دیگری ندارد.
- $\text{Chi-Square} < 3.84$: رابطه مشاهده شده شانسی است.
- $\text{Kulczynski} < 0.1$: رابطه بسیار سست و نامتعادل است.

۶. نتیجه‌گیری نهایی

این پروژه با موفقیت کامل انجام شد. پیاده‌سازی دستی الگوریتم‌ها صحت عملکرد کدهای استاندارد را تایید کرد. تحلیل‌ها ثابت کرد که در این فروشگاه، چیدمان کالاها باید به گونه‌ای باشد که شیر و شکلات و همچنین بستنی و کره در نزدیکی هم قرار گیرند، زیرا وابستگی خرید آن‌ها با معیارهای دقیق آماری اثبات شده است.