



Clustering & Classification

Clustering

Clustering Algorithms

- داده‌های خود را بر اساس برخی از ویژگی‌های عددی و Categorical خوشه‌بندی کنید.
 - توجه کنید که فیچرهایی (Features) که انتخاب می‌کنید باید در کنار هم معنا داشته باشند. در واقع باید نمونه‌های (Instances) مشابه در یک خوشه قرار بگیرند. با بررسی الگوهای موجود در کلاسترها، شباهت اعضای هر کلاستر را در داکيومنت خود تشریح کنید.
- یک بار هم خوشه‌بندی را بر اساس ویژگی‌های زمانی (در صورت وجود در دیتاست، مثل سال، ماه، فصل) و یا یک زیرمجموعه خاص از ویژگی‌ها انجام دهید. با این کار، الگوهایی از هر کلاستر استخراج کنید و بررسی کنید در بازه‌های زمانی مختلف (یا دسته‌بندی‌های خاص) داده‌ها چه رفتاری داشته‌اند و چه ویژگی‌های مشترکی دارند.
- پیاده‌سازی جامع خانواده‌های الگوریتم‌های K-means و Density-Based :
 - خانواده K-means (Centroid-based): تنها به K-means بسنده نکنید؛ باید تمام نسخه‌های اصلی این خانواده را پیاده‌سازی و مقایسه کنید، شامل:
 - Standard K-means ✓
 - K-Medoids (PAM) ✓
 - K-Medians ✓
 - Fuzzy C-Means (Soft Clustering) ✓
 - Kernel K-means (برای داده‌های غیرخطی) ✓
 - Bisecting K-means ✓
 - خانواده Density-based: علاوه بر DBSCAN، الگوریتم‌های پیشرفته‌تر این خانواده را نیز اجرا کنید، شامل:
 - DBSCAN ✓
 - OPTICS (جهت غلبه بر مشکل انتخاب شعاع eps ثابت) ✓
 - Hierarchical DBSCAN) HDBSCAN - جهت خوشه‌بندی با چگالی‌های متغیر. ✓

Clustering

Clustering Algorithms

- تحلیل حساسیت و مقایسه:
 - حساسیت به نویز (Noise Robustness): تمام الگوریتم‌های بالا را از نظر برخورد با داده‌های پرت (Outliers) مقایسه کنید. دقیقاً مشخص کنید کدام الگوریتم‌ها (مثل K-Medians یا خانواده Density-based) نسبت به نویز مقاوم‌ترند و کدام یک (مثل Standard K-means) به شدت تحت تاثیر قرار می‌گیرند؟
 - داده‌های غیرخطی (Non-linear Geometries): بررسی کنید کدام الگوریتم‌ها (مانند Kernel K-means یا DBSCAN) قادر به شناسایی خوشه‌های با اشکال پیچیده و غیرکروی هستند و کدام یک شکست می‌خورند.
- تصویرسازی: خروجی تک تک الگوریتم‌های ذکر شده را پلات کنید (Plot) و در گزارش نهایی کنار هم قرار دهید تا تفاوت در شکل‌گیری مرز خوشه‌ها و مراکز آن‌ها به وضوح قابل مشاهده باشد.
- برای خانواده K-means، عملیات Hyperparameter tuning (پیدا کردن بهترین K) انجام دهید و برای پارامترهای خانواده DBSCAN (مثل eps و min_samples) حداقل سه حالت مختلف را تست کنید.
- برای کلاسترینگ خود یک معیار ارزیابی (مانند Silhouette Score و ...) پیدا کنید و میزان خوبی مدل خود را گزارش دهید.
- الگوهای معنایی (Semantic Patterns) که در خوشه‌ها شناخته می‌شوند را مورد تحلیل و بررسی قرار دهید.

Clustering Visualization

- از نمودارها و تصویرسازی‌ها (مانند PCA برای کاهش ابعاد و نمایش دوبعدی) برای نمایش الگوهای خوشه‌بندی بهره ببرید. این تصاویر را در داکيومنت خود تحلیل کنید.

Classification

Binary Classification

1. ابتدا ویژگی‌هایی را انتخاب کنید که نشان‌دهنده موفقیت/شکست، تایید/رد، یا هر وضعیت دوگانه مهمی در دیتاست شما باشد (داده‌های ورودی یا همان X).
- ستونی تحت عنوان `Label_Binary` (نامی متناسب با موضوع خود انتخاب کنید، مثلاً `is_successful` یا `has_churned`) ایجاد کنید. اگر این ستون از قبل وجود دارد از همان استفاده کنید.
- این ستون را به عنوان لیبل (`Target`) در نظر بگیرید. در واقع ما به دنبال پیش‌بینی وقوع یک رویداد یا تعلق به یک کلاس خاص هستیم. بر اساس فیچرهای انتخابی، دلایل قرارگیری داده‌ها در هر کلاس را بررسی کنید.
2. داده‌های خود را به دو مجموعه `Train` و `Test` تقسیم کنید.
3. چند مدل از جمله `Naive Bayes`، `SVM`، `KNN`، `Decision Tree` را بر روی داده‌های خود آموزش داده و دقت (`Accuracy`) را روی داده‌های `Train` محاسبه کنید. (استفاده از سه مدل ذکر شده الزامی است).
4. برای مدل‌های خود `Hyperparameter tuning` انجام دهید تا به بهترین دقت برسید و از `Overfit` شدن مدل‌های خود جلوگیری کنید.
5. در نهایت دقت مدل‌های خود را بر روی داده‌های `Test` به دست آورید. همچنین معیارهای `Precision`، `Recall`، `accuracy` و `F1-Score` را برای داده‌های تست محاسبه و تحلیل کنید.
6. در این بخش به بررسی دلایل قرارگیری داده‌ها در کلاس مثبت یا منفی بپردازید؛ با توجه به ویژگی‌های انتخاب شده، چرا یک نمونه در دسته هدف قرار می‌گیرد یا نمی‌گیرد؟ این موارد را در داکيومنت بررسی کنید.

Classification

Multiclass Classification / Discretization

- در این بخش ویژگی‌هایی را انتخاب کنید که بتوانند یک متغیر پیوسته مهم (Numerical Target) در دیتاست شما را پیش‌بینی کنند (مثلاً قیمت، نمره، میزان فروش و ...).
- توجه کنید این ستون عددی باید گسسته‌سازی (Discretization/Binning) شود و به یک ستون Categorical تبدیل شود (مثلاً: کم، متوسط، زیاد).
 - تمام مراحل بخش قبل (آموزش مدل‌ها، تیونینگ و ارزیابی) را صرفاً با ویژگی‌های متفاوت و لیبل جدید که اکنون کتگوریکال شده است، انجام دهید.
 - در واقع در این بخش با انتخاب فیچرهای مناسب، قرار است مقدار بازه‌ای (Range) متغیر هدف را پیش‌بینی کنید.

Additional Notes

تمام بخش‌ها و نتایج خود را در داکيومنت نهایی تحلیل و بررسی کنید.
(کد خود را در گزارش کپی نکنید و توضیحش ندهید، بلکه نتایج و لاجیک را
توضیح دهید!)

پروژه تنها به صورت انفرادی قابل انجام بوده و در صورت وجود هرگونه تشابه بین دو کد یا عدم تسلط به
روند، نمره منفی به دانشجویان داده میشود.

کپی و استفاده کورکورانه از منابع اینترنتی، یا ابزارهایی نظیر Chat-GPT ممنوع است.

فایل‌های نهایی پروژه شامل کد و گزارش را با فرمت StudentNumber_Name_#3.zip زیپ کرده
و در VU بارگذاری کند.

